



ИИ-ассистент технической поддержки

Дипломный проект курса
«ИИ-разработчик: от
API до агентов»

Автор: Даниленко С. С.

Задача и пользователь

Пользователь: сотрудники АО «УК «БМЗ» (первая линия УИТ, технические специалисты)

Домены: 1С:ERP, 1С:ЗУП, Сети, Help Desk, КСЭД

Что закрывает система:

Ответы на типовые вопросы по корпоративным ИТ-системам

Автоматическая эскалация сложных вопросов в HelpDesk

Отправка ответа/заявки на email с подтверждением пользователя



Почему здесь нужен ИИ

Проблема обычного поиска:

- Ключевой поиск не работает на смысловых запросах («Как получить доступ к 1С?» vs «Инструкция по оформлению заявки»)
- FAQ-страница не отвечает на составные вопросы
- Сотрудник не знает **в каком документе** искать

Что даёт RAG-подход:

- Понимает смысл запроса через эмбединги
- Находит **фрагменты** в 70+ документах
- Генерирует ответ с **прямыми ссылками** на источники

База знаний


Корпус:

- **71 документ** из корпоративной базы знаний
- Форматы: PDF, DOCX
- **646 чанков** в векторной базе Qdrant
- Средний размер документа: 20–50 страниц
- Категории: 1С:ERP, Сети, HelpDesk, КСЭД, КСМПП

Почему именно эти документы:

- Реальные инструкции и регламенты, которыми пользуется УИТ
- Охватывают 90% типовых обращений

Архитектура



Выбор модели

Параметр - Значение

- Модель - frob/qwen3.5-instruct:4b
- Хост - Ollama (локально)
- GPU - RTX 5070, 12 ГБ VRAM
- VRAM модели ~3 ГБ (влезает с запасом)
- Latency ~2–5 сек на ответ

Почему локально:

- On-premise — данные не покидают контур
- Нет затрат на API
- Работает без интернета
- Требование службы безопасности организации

✗ Ограничение 4B-модели: слабее на сложных многошаговых запросах

Альтернативы: GPT-4o-mini, GigaChat, YandexGPT — отклонены по требованию on-premise.

Хранение и поиск

Основные параметры:

- Векторная БД: Qdrant
- Модель эмбедингов: BAAI/bge-m3 (1024 dim, мультязычная)
- Чанкинг: size=512, overlap=64
- Метрика: COSINE (эквивалентна DOT для L2-норм. BGE-M3 — проверено экспериментом 5/5)
- Порог релевантности: RAG_SCORE_THRESHOLD=0.62

Почему 512/64:

- 512 токенов — оптимально для технических инструкций
- Не рвёт смысл, влезает в контекст LLM
- 64 токена перекрытия — сохраняет связность




Агентный слой

Один агент с инструментами (LangGraph):

1. `search_knowledge_base` — поиск по RAG-базе (безопасный)
2. `send_email` — отправка письма (требуется подтверждения, NIL)

NIL — Human-in-the-loop:

1. Агент готовит draft письма
 2. Граф приостанавливается (interrupt)
 3. Пользователь видит inline-кнопки «Отправить / Отмена»
 4. Реальная отправка — только после подтверждения
- Чекпоинтер — Postgres: состояние переживает рестарт.



Заявка в HelpDesk: Как открыть документ поступления товаров и услуг в 1С:ЕРП?

Входящие x



ya.ss-danilenko@yandex.ru

14:36 (8 минут назад)



кому: мне ▾

Пользователь: Sergey Danilenko (ID: 443426947, @it_sd)

Как открыть документ поступления товаров и услуг в 1С:ЕРП?

Требуется консультация специалиста.

Поведение при сбоях

Ситуация	Поведение
Score < 0.62	Код-гард → честный отказ без вызова LLM
Модель недоступна	HTTP 503, повтор через 30 сек
Redis недоступен	Работает без кеша (graceful degradation)
Postgres недоступен	Чекпоинты в памяти
Ошибка трейсинга	Не роняет приложение
Таймаут LLM	180 сек, 3 retry

Результат

Оценка через RAGAS на golden dataset из 15 вопросов:

Метрика	1-й запуск	3-й запуск	Δ
Faithfulness	0.876	0.933	+0.06
Answer Relevancy	0.524	0.638	+0.11
Context Precision	0.734	0.906	+0.17
Context Recall	0.667	0.933	+0.27
Factual Correctness	0.230	0.585	+0.36
Has Citation	—	15/15	✓

Трейсинг

PHOENIX

Search

Tracing 1

Dashboards

Datasets & Experiments 0

Evaluators 0

Prompts 0

Playground

Chat

REST API

GraphQL

Update available
Phoenix v2014.0 is now available with new features and improvements.
[View release notes](#)

Star on GitHub 11.5k

Settings

Account

Projects > default

Spans Traces Sessions Metrics Config

Traffic

parent_id is None

	status	kind	name	input	output
	✓	chain	LangGraph	{ "graph": null, "update": null, "resume": true, "goto": ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	В базе знаний нет от...
	✓	retriever	VectorIndexRetriever...	как открыть документ поступление товаров и у...	{ "NodeWithScore(no...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	Для подключения к ...
	✓	retriever	VectorIndexRetriever...	как подключиться к wifi	{ "NodeWithScore(no...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	Для подключения к ...
	✓	retriever	VectorIndexRetriever...	как подключить wifi интернет	{ "NodeWithScore(no...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	Для создания новой ...
	✓	retriever	VectorIndexRetriever...	как создать новую заявку на транспорт	{ "NodeWithScore(no...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	Для создания новой ...
	✓	retriever	VectorIndexRetriever...	как создать новую заявку на транспорт	{ "NodeWithScore(no...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ...	{ "messages": [{ "type": ...
	✓	chain	LangGraph	{ "graph": null, "update": null, "resume": true, "goto": ...	{ "messages": [{ "type": ...
	✓	llm	Ollama.complete	{ "args": ["Ниже — пронумерованные источники ...	В базе знаний нет от...

Trace 37a7f3062292ee176c6aba6ea88cfc41

Status OK Total Cost \$0 Latency 695ms

LangGraph

confirm_and_send

force_finish

Info Attributes Events

Annotations

Input

Output

18°C
Överväg. moln.

Поиск

Пуск

14:53
18.09.2026



Ограничения и планы

Ограничения:

- 4B-модель ограничивает Factual Correctness (0.59) и работу со сложными многошаговыми запросами
- Сценарий «отправь ответ на произвольный email» работает нестабильно
- Нет интеграции с 1C: Itilium напрямую (только через почту)

План развития:

- Переход на 7B–14B модель при апгрейде GPU
- Интеграция с 1C:Itilium через REST
- Интеграция с мессенджером Express
- Расширение golden dataset до 50 вопросов
- Гибридный поиск (dense + BM25)

Спасибо за внимание

Репозиторий: github.com/ssdanilenko-glitch/itassistant_final

Готов ответить на вопросы

