



ИИ-ассистент технической поддержки

Дипломный проект курса
«ИИ-разработчик: от
API до агентов»

Автор: Даниленко С. С.

Задача и пользователь

Пользователь: сотрудники АО «УК «БМЗ» (первая линия УИТ, технические специалисты)

Домены: 1С:ЕРП, 1С:ЗУП, КСМПП, Сеть, Почта, Прочее

Что закрывает система:

Ответы на типовые вопросы по корпоративным ИТ-системам

Автоматическая эскалация сложных вопросов в HelpDesk

Получение статуса заявки, отправленной на HelpDesk



Почему здесь нужен ИИ

Проблема обычного поиска:

- Ключевой поиск не работает на смысловых запросах («Как получить доступ к 1С?» vs «Инструкция по оформлению заявки»)
- FAQ-страница не отвечает на составные вопросы
- Сотрудник не знает **в каком документе** искать

Что даёт RAG-подход:

- Понимает смысл запроса через эмбединги
- Находит **фрагменты** в 70 документах
- Генерирует ответ с **прямыми ссылками** на источники

База знаний


Корпус:

- **70 документов** из корпоративной базы знаний
- Форматы: PDF, DOCX
- **646 чанков** в векторной базе Qdrant
- Средний размер документа: 20–50 страниц
- Категории: 1С:ERP, 1С:ЗУП, КСМПП, Сеть, Почта, Прочее

Почему именно эти документы:

- Реальные инструкции и регламенты, которыми пользуется УИТ
- Охватывают существенное количество типовых обращений

Архитектура



/start 14:27 ✓

Привет! Я ИТ-ассистент технической поддержки.

Чтобы задать вопрос — используйте `/ask` или просто напишите его текстом.

Команды:

- `/ask` — задать вопрос с выбором темы
- `/help` — справка по командам
- `/clear` — очистить историю диалога
- `/cancel` — отменить текущий сценарий

/ask 14:27 ✓

Выберите тему из списка или напишите свой вопрос:

- 1С:ЕРП
- 1С:ЗУП
- КСМПП
- Сеть
- Почта
- Прочее
- Отмена

MA 14:27

Вы выбрали тему: Net

Напишите ваш вопрос: 14:27

/ask 14:29 ✓

Как подключиться к wifi?

MA 14:29

Здравствуйте, Сергей!

Для подключения к корпоративной сети Wi-Fi есть два основных варианта в зависимости от типа сети:

Вариант 1: Подключение к сети «BMZ-Internet»

1. Выберите сеть **BMZ-Internet** из списка доступных сетей Wi-Fi.
2. Введите пароль: **bmz**
3. Нажмите кнопку «Подключиться».

Вариант 2: Подключение к сети «Zavod»

Для подключения к этой сети требуется использование корпоративного сертификата:

1. Выберите сеть **Zavod**.
2. В поле «Удостоверение» укажите логин вашей учетной записи рабочего компьютера (без префикса **ad**).
3. В поле «Пароль» введите пароль от этой учетной записи.
4. В поле «Сертификат» выберите вариант «Не подтверждать».

Если у вас возникли дополнительные вопросы по настройке, пожалуйста, уточните, к какой именно сети вы пытаетесь подключиться.

Источники:

- Инструкция по подключению к сети Wi-Fi BMZ-Internet.docx
- Инструкция по подключению к сети Wi-fi ZAVOD.docx

MX

Выбор модели

Параметр - Значение

- Модель - frob/qwen3.5-instruct:4b
- Хост - Ollama (локально)
- GPU - RTX 5070, 12 ГБ VRAM
- VRAM модели ~2.5–3 ГБ (влезает с запасом)
- Latency ~2–5 сек на ответ
- RAM — 32 ГБ (минимум), 64 ГБ (рекомендуется)
- Стоимость - 250 тыс. руб.

Почему локально:

- On-premise — данные не покидают контур
- Нет затрат на API
- Работает без интернета
- Требование службы безопасности организации

Ограничение 4B-модели: слабее на сложных многошаговых запросах

⁶ Альтернативы: GPT-4o-mini, GigaChat, YandexGPT — отклонены по требованию on-premise.

Хранение и поиск

Основные параметры:

- Векторная БД: Qdrant
- Модель эмбедингов: BAAI/bge-m3 (1024 dim, мультязычная)
- Чанкинг: size=512, overlap=64
- Метрика: COSINE (эквивалентна DOT для L2-норм. BGE-M3 — проверено экспериментом 5/5)
- Порог релевантности: RAG_SCORE_THRESHOLD=0.62

Почему 512/64:

- 512 токенов — оптимально для технических инструкций
- Не рвёт смысл, влезает в контекст LLM
- 64 токена перекрытия — сохраняет связность



Агентный слой


Один агент с инструментами (LangGraph):

1. `search_knowledge_base` — поиск по RAG-базе (безопасный)
2. `get_helpdesk_status` — статус заявки в HelpDesk (безопасный)
3. `send_email` — отправка письма (требуется подтверждения, HIL)

HIL — Human-in-the-loop:

1. Агент готовит draft письма
2. Граф приостанавливается (interrupt)
3. Пользователь видит inline-кнопки «Отправить / Отмена»
4. Реальная отправка — только после подтверждения

Чекпоинтер — Postgres: состояние переживает рестарт.



Заявка в HelpDesk: Как открыть документ поступления товаров и услуг в 1С:ЕРП?

Входящие x



ya.ss-danilenko@yandex.ru

14:36 (8 минут назад)



кому: мне

Пользователь: Sergey Danilenko (ID: 443426947, @it_sd)

Как открыть документ поступление товаров и услуг в 1С:ЕРП?

Требуется консультация специалиста.

Поведение при сбоях

Ситуация	Поведение
Score < 0.62	Код-гард → честный отказ без вызова LLM
LLM (Ollama) недоступна	HTTP 503, код llm_unavailable; в SSE — событие type="error"
Таймаут LLM	180 сек, 3 retry
Redis недоступен	Работает без кеша (graceful degradation)
Ошибка трейсинга	Не роняет приложение
Postgres недоступен	Ошибка инициализации чекпоинтера (fallback не реализован)



Результат

Оценка через RAGAS на golden dataset из 15 вопросов:

Метрика	1-й запуск	3-й запуск	Δ
Faithfulness	0.876	0.933	+0.06
Answer Relevancy	0.524	0.638	+0.11
Context Precision	0.734	0.906	+0.17
Context Recall	0.667	0.933	+0.27
Factual Correctness	0.230	0.585	+0.36
Has Citation	—	15/15	✓

Трейсинг

- «Phoenix — локальный UI, OTLP-совместимый трейсинг».
- «Видны шаги LangGraph, вызовы инструментов, RAG-поиск, LLM».

Phoenix

Search

Tracing1

Dashboards

Datasets & Experiments0

Evaluators0

Prompts0

Playground

Chat

REST API

GraphQL

Update available

Phoenix v2019.0 is now available with new features and improvements.

View release notes

Star on GitHub

11.7k

Settings

Account

default - Projects

Projects > default

Spans

Traces

Sessions

Metrics

Config

Traffic

600

300

0

01:10

02:10

03:10

04:10

error

ok

unset

parent_id is None

	status	kind	name	Input	output
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	chain	LangGraph	{ "graph": null, "update": null, "resume": true, "goto": ... }	{ "messages": [{ "t...
	✓	retriever	VectorIndexRetriever...	открыть документ Поступление товаров и услуг...	["<NodeWithScor...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	llm	Ollama.acomplete	{ "args": ["Ниже — пронумерованные источники ...	Для подключения...
	✓	retriever	VectorIndexRetriever...	подключение wifi доступ в интернет БМЗ	["<NodeWithScor...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	llm	Ollama.acomplete	{ "args": ["Ниже — пронумерованные источники ...	Для подключения...
	✓	retriever	VectorIndexRetriever...	подключение к ИТ-ресурсам БМЗ подача заявки	["<NodeWithScor...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	llm	Ollama.acomplete	{ "args": ["Ниже — пронумерованные источники ...	Для подключения...
	✓	retriever	VectorIndexRetriever...	подключение к ИТ-ресурсам БМЗ подача заявки	["<NodeWithScor...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...
	✓	chain	LangGraph	{ "graph": null, "update": null, "resume": true, "goto": ... }	{ "messages": [{ "t...
	✓	retriever	VectorIndexRetriever...	как открыть документ Поступление товаров и у...	["<NodeWithScor...
	✓	chain	LangGraph	{ "iteration_count": 0, "tool_results": [], "draft": null, ... }	{ "messages": [{ "t...

Trace

ID 091d2c55407307eb7ae016f5d9b73559

Share

StatusOK

Total Cost\$0

Latency987ms

View Session

Search trace

LangGraph

call_model

ChatOpenAI 1,900

route_after_model

execute_tool

get_helpdesk_status

call_model

ChatOpenAI 2,012

route_after_model

force_finish

Info

Attributes

Events0

Annotations0

Input

1 {
2 "iteration_count": 0,
3 "tool_results": [],
4 "draft": null,
5 "sent": false,
6 "messages": [
7 {
8 "type": "human",
9 "data": {
10 "content": "Пользователь: Sergey
Danilenko (ID: 443426947, @it_sd)\n\nКакой
статус у заявки HD-2026-24358?",
11 "additional_kwargs": {},
12 "response_metadata": {},
13 "type": "human",
14 "name": null,
15 "id": "72f6ffc5-36e1-462e-8edd-
83d77f8c7c96"
16 }
17 }
18]
19 }

Output

1 {
2 "messages": [
3 {
4 "type": "human",
5 "data": {
6 "content": "Пользователь: Sergey
Danilenko (ID: 443426947, @it_sd)\n\nКакой
статус у заявки HD-2026-24358?",
7 "additional_kwargs": {},
8 "response_metadata": {},
9 "type": "human",
10 "name": null,
11 "id": "72f6ffc5-36e1-462e-8edd-
83d77f8c7c96"
12 }
13 }
14]
15 }

localhost:6006/projects/UHJvamVjdDox/spans/091d2c55407307eb7ae016f5d9b73559?timeRangeKey=7d&selectedSpanNodeid=U3BhbjoxMTY3

Ограничения и планы

Ограничения:

- 4B-модель ограничивает работу со сложными многошаговыми запросами
- Сценарий «отправь ответ на произвольный email» работает нестабильно
- Нет интеграции с 1C: Itilium напрямую (только через почту)

План развития:

- Переход на 7B–14B модель при апгрейде GPU
- Интеграция с 1C:Itilium через REST
- Интеграция с мессенджером Express
- Расширение golden dataset до 50 вопросов
- Гибридный поиск (dense + BM25)

Спасибо за внимание

Репозиторий: https://github.com/ssdanilenko-glitch/ll_assistant_final

